# Réunion 17/01

## 1. Problèmes d'Exécution de GPT-3 en Local

#### Difficulté de traitement sur nos machines

L'un des principaux défis soulevés est l'exécution de GPT-3 sur nos ordinateurs personnels. Une tentative sur VSCode a pris plus de 20 minutes sans donner de résultats concluants.

#### Limitation matérielle

Notre tuteur a souligné que pour exécuter GPT-3 en local, un **GPU de plus de 12 Go de VRAM** est indispensable. Malheureusement, nos ordinateurs ne disposent pas d'une telle configuration, ce qui complique la tâche.

### **Solutions possibles**

- Utilisation des machines du laboratoire : Ces machines possèdent des GPU adaptés, mais elles fonctionnent sur un système de batch jobs et sont partagées entre plusieurs utilisateurs.
- Explorer des alternatives cloud : Bien que nous préférions travailler avec des ressources locales, nous devons envisager l'utilisation de plateformes comme Google Colab pour des tests rapides.

# 2. Accès aux Ressources GPU

## Disponibilité des GPU du laboratoire

L'accès aux ressources GPU du labo est limité, car plusieurs stagiaires les utilisent déjà. Deux options s'offrent à nous :

- 1. **Exécution interactive** si les ressources sont disponibles au moment voulu.
- 2. **Batch jobs**, où l'on soumet un script qui sera exécuté dès qu'un GPU est libre.

#### Possibilité d'accès prioritaire

Notre tuteur a mentionné que dans certains cas, un accès prioritaire peut être accordé en cas de besoin urgent. De plus, il est possible qu'il y ait d'autres **GPU plus puissants** moins sollicités en ce moment.

# 3. Analyse de BERTopic et Clustering

### Comprendre le Score des Mots (TopicWordScore)

L'un des éléments discutés était le **TopicWordScore**, qui permet de convertir les données textuelles en **embeddings** et de calculer la probabilité d'un mot d'appartenir à un sujet donné.

#### Hiérarchie des Clusters

Nous avons également exploré la hiérarchie de clustering, qui permet de mieux visualiser les relations entre les clusters. Cela repose sur une **matrice de similarité**, qui aide à analyser les connexions entre les différents groupes de sujets.

#### Amélioration des Visualisations

Les visualisations existantes nécessitent une amélioration, notamment en ce qui concerne l'intégration des **espaces et des clusters** dans les graphiques. Une meilleure présentation des résultats facilitera leur interprétation.

# 4. Organisation des Environnements de Travail

### Problème de Reproductibilité

Un autre point important concerne la gestion des environnements Python. Actuellement, un manque d'organisation rend difficile la **reproductibilité des expériences**, ce qui peut poser problème dans nos analyses.

## **Bonnes Pratiques Recommandées**

Notre tuteur nous a conseillé plusieurs solutions pour mieux gérer nos environnements :

- Créer un fichier requirements.txt pour lister les dépendances utilisées.
- Garder une trace des commandes d'installation pour s'assurer que tout le monde utilise la même configuration.
- Stocker ces informations dans un fichier ou un notebook pour éviter les pertes.

## 5. Plan d'Action à Venir

### Séance de Travail avec Sabrina

Une réunion doit être organisée avec **Sabrina**, qui pourra nous aider à clarifier les aspects techniques et fonctionnels de notre projet.

### Vérification des Accès aux GPU

Nous devons confirmer **quels GPU locaux sont disponibles** et apprendre à utiliser efficacement les batch jobs pour éviter les longues attentes.